ENTREGA TÉCNICA / FASE 2

Empreendedorismo Feminino no Brasil

Unificação, tratamento, modelagem e armazenamento dos dados

Equipe: Kauã Kley, Luan Victor e Beatriz Costa
PNADC trimestral | 1º e 2º trimestres de 2026
Base fase2-v1 / entrega fase2-v2 | Preparada em 13/10/2026

Resultado verificado	Quantidade
Linhas originais dos dois arquivos	1.032.879
Observações de ocupados na base tratada	464.457
Campos de origem / indicadores / rastreabilidade	21 / 5 / 2
Registros inválidos, duplicatas ou conflitos	0

Situação da atividade

Entregável	Situação
1. Base de dados tratada	Concluído: CSV e Parquet, tipos e auditoria.
2. Processo de tratamento	Concluído: Python, SQL e documentação. Repositório da equipe: github.com/yLu4n/big_data.
3. Banco de dados em nuvem	big_data em localhost:5432, esquema ef, carregado e validado. Hospedagem Aiven pendente: serviço ainda não criado.

A entrega contém uma base efetivamente processada e o banco big_data carregado e validado no esquema ef. A etapa de nuvem permanece pendente, conforme informação do usuário; nenhuma evidência de hospedagem foi simulada.

Unidade de análise: observação de pessoa por trimestre. A soma de registros dos dois períodos não representa pessoas distintas no semestre.

02 / Origem e decisões de tratamento

Fontes e versão utilizada

Os dois TXT, o layout SAS e os dicionários XLS foram lidos na pasta Projeto_Empreendedorismo_Feminino fornecida pelo usuário. A documentação atribui a fonte à PNAD Contínua trimestral do IBGE. Os arquivos originais permaneceram intactos. A autenticidade externa não foi revalidada por novo download.

Arquivo	Originais	Ocupados	Fora do universo
PNADC_012026.txt	511.149	228.357	282.792
PNADC_022026.txt	521.730	236.100	285.630
Total	1.032.879	464.457	568.422

Todas as linhas tinham 3.478 caracteres, sem a quebra de linha. As 21 variáveis foram conferidas entre posições do layout SAS, posições do dicionário e disponibilidade nos dois trimestres.

Decisão	Aplicação e justificativa
Filtro de ocupação	VD4002=1. Preserva o universo definido no levantamento.
Geografia e sexo	Todas as UFs e ambos os sexos. Bahia e Salvador são indicadores para consultas.
Valores ausentes	Brancos opcionais viram NULL. Sem imputação de renda e sem substituição por zero.
Precisão	Peso e renda convertidos com Decimal; identificadores textuais preservam zeros.
Duplicatas e erros	Mesma chave e linha idêntica: remover repetição. Conteúdo divergente: excluir todas as ocorrências da chave e registrar para revisão.
Volume e memória	Leitura em fluxo; deduplicação SQLite em disco; exportação em blocos de 25.000. Sem subamostragem ou agregação antes da carga.

Proveniência verificável

PNADC_012026.txt | 1.778.798.520 bytes
SHA-256: 8406bfc994e69e1334b46396a17d0fd1f5d52948ec952107c8bc4d6f95f6703d

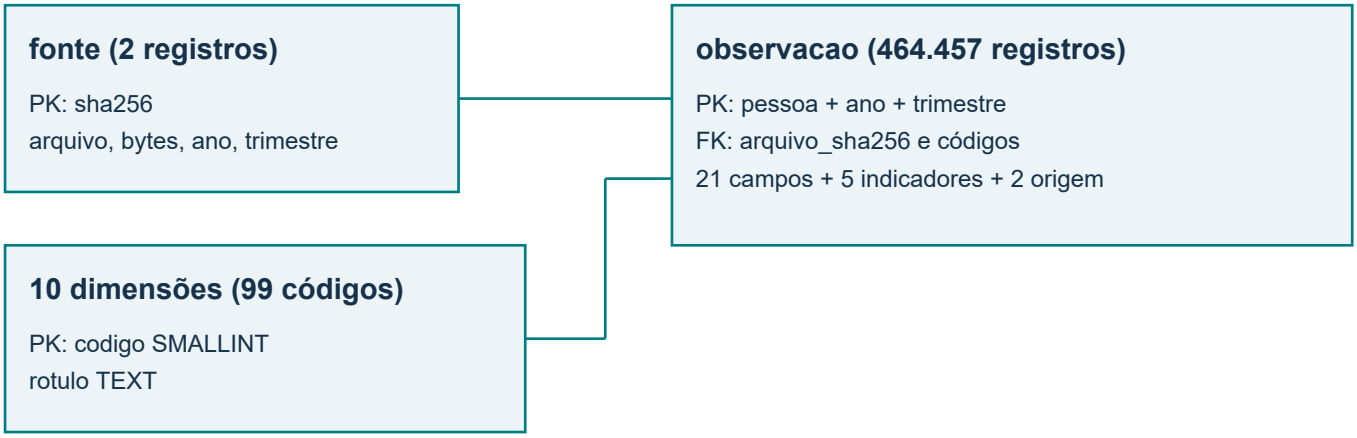
PNADC_022026.txt | 1.815.620.400 bytes
SHA-256: 03e399334ea304f4d0cc4444702c395ad9b369163c1e760ebc875b48c3a2c80e

Cada observação conserva o hash do arquivo e o número da linha original. Os hashes do layout e dos dicionários, além dos artefatos tratados, estão em dados/auditoria.json.

03 / Modelagem relacional

Estrutura do esquema ef

O modelo mantém o detalhe pessoa-trimestre em uma tabela de observações e separa rótulos em dimensões. Essa escolha reduz repetição de texto, valida códigos com chaves estrangeiras e facilita filtros e agregações sem perder a rastreabilidade.



Entidade	Campos e relacionamento
fonte	arquivo VARCHAR(80), sha256 CHAR(64) PK, bytes BIGINT, ano SMALLINT e trimestre SMALLINT.
observacao	Chave composta: ano, trimestre, upa, v1008, v1014, v1016 e v2003. UNIQUE adicional: arquivo_sha256 + linha_origem.
dim_uf e dim_capital	UF e capital municipal. Cada código na observação referencia a dimensão correspondente.
dim_v2007 e dim_v2010	Sexo e cor/raça, incluindo códigos previstos como ignorado.
dim_vd3004 e dim_vd4002	Nível de instrução e condição de ocupação. A tabela fato aceita somente ocupados.
dim_vd4009 e dim_vd4010	Posição/categoria de emprego e grupamento de atividade.
dim_v4019 e dim_v4018	Registro CNPJ e faixa de pessoas no negócio. Cada dimensão usa codigo SMALLINT e rotulo TEXT.

Integridade e índices

CHECKs validam período, ocupação, idade, peso, renda, identificação, geografia e indicadores. Há índice de período/UF/sexo e índice parcial para empreendedoras. O SQL completo está em sql/01_estrutura.sql. As chaves de pessoa incluem trimestre para preservar reaparições entre períodos.

04 / Campos e tipos da base tratada

Nomes físicos em minúsculas, correspondentes às variáveis de origem. NULL é permitido somente quando indicado. O dicionário JSON inclui posição e largura no TXT.

Campo	Significado / regra	Tipo PostgreSQL	NULL
ano	Ano de referência	SMALLINT	Não
trimestre	Trimestre	SMALLINT	Não
uf	Unidade da Federação	SMALLINT	Não
capital	Município da capital	SMALLINT	Sim
upa	Unidade Primária de Amostragem	VARCHAR(9)	Não
estrato	Estrato amostral	VARCHAR(7)	Não
v1008	Seleção do domicílio	VARCHAR(2)	Não
v1014	Painel	VARCHAR(2)	Não
v1016	Número da entrevista	VARCHAR(1)	Não
v1028	Peso trimestral calibrado	NUMERIC(18,8)	Não
v2003	Ordem da pessoa	VARCHAR(2)	Não
v2007	Sexo	SMALLINT	Não
v2009	Idade em anos	SMALLINT	Não
v2010	Cor ou raça	SMALLINT	Não
vd3004	Nível de instrução	SMALLINT	Não
vd4002	Condição de ocupação	SMALLINT	Não
vd4009	Posição e categoria do emprego	SMALLINT	Não
v4019	Registro no CNPJ	SMALLINT	Sim
v4018	Faixa de pessoas no negócio	SMALLINT	Sim
vd4010	Grupamento de atividade	SMALLINT	Não
vd4016	Renda habitual do trabalho principal	NUMERIC(12,2)	Sim
is_bahia	UF=29	BOOLEAN	Não
is_salvador	UF=29 e Capital=29	BOOLEAN	Não
is_empreendedor	VD4009 em 8 ou 9	BOOLEAN	Não
is_empreendedora	Mulher e empreendedora	BOOLEAN	Não
formalizada	CNPJ; apenas empreendedores	BOOLEAN	Sim
arquivo_sha256	SHA-256 da fonte original	CHAR(64)	Não
linha_origem	Linha original do TXT, iniciada em 1	BIGINT	Não

A renda é nominal, em reais. O peso mantém oito casas decimais sem conversão intermediária a ponto flutuante. V4018 é uma faixa e não um número exato de pessoas.

05 / Validação executada e armazenamento

Carga real no PostgreSQL local

A conexão informada pelo usuário foi configurada em localhost:5432/big_data, no PostgreSQL 18.6. O esquema ef foi criado e carregado com chaves, restrições e views. As tabelas existentes no esquema empreendedorismo não foram alteradas. O banco informado permanece disponível; o backup de ef foi restaurado e conferido em outra instância temporária.

Verificação	Resultado
Linhas carregadas / fontes / dimensões	464.457 / 2 / 10 (99 códigos)
Contagens por trimestre	1º: 228.357; 2º: 236.100
Chaves repetidas no PostgreSQL	0 grupos
Inconsistências de ocupação, peso, idade e indicadores	0
CSV versus Parquet	Todas as células conferidas: 464.457 linhas e 28 colunas
Hashes dos artefatos tratados	Conferidos; equivalem à auditoria
NULL em renda / renda zero informada	9.261 / 0
CNPJ ausente entre empreendedores	0

Ausências preservadas

Campo	Nulos	Interpretação
capital	349.127	Não identificado como capital no campo.
v4019 / formalizada	317.732	Fora do universo de empreendedores nesta base.
v4018	92.868	Ausência preservada conforme universo da pergunta.
vd4016	9.261	Renda ausente; não transformada em zero.

Volume medido nesta execução

Artefato	Tamanho
TXT originais (dois arquivos)	3.594.418.920 bytes (3,59 GB)
CSV tratado	82.825.879 bytes (82,83 MB)
Parquet tratado	6.504.400 bytes (6,50 MB)
Tabela de observações e índices	182.091.776 bytes (182,09 MB)
Banco big_data (todos os esquemas)	305.469.119 bytes (305,47 MB)

MB e GB usam base decimal. O esquema ef ocupa 182.509.568 bytes. O volume de big_data inclui outros esquemas e índices; não corresponde ao Parquet. A medida local de aproximadamente 323 MB citada no levantamento não foi reutilizada como resultado: este modelo foi medido novamente. O consumo no Aiven só poderá ser confirmado após a carga.

06 / Views e conferência das estimativas

Estimativas pontuais por trimestre

As views v_recortes, v_resumo_geografico e v_perfil_empreendedores preservam o detalhe no banco e calculam resumos na consulta. O total estimado é a soma de V1028. A renda média usa soma(peso × renda) / soma(peso), considerando no denominador apenas observações com renda informada no mesmo grupo.

Conferência das empreendedoras

Trimestre	Recorte	Amostra	Estimativa ponderada	Renda média (R$)
1º / 2026	Brasil	23.902	10.213.256,46	3.388,03
1º / 2026	Bahia	1.152	692.208,64	1.817,88
1º / 2026	Salvador	227	154.568,58	2.282,86
2º / 2026	Brasil	24.778	10.320.820,78	3.455,99
2º / 2026	Bahia	1.219	699.114,10	2.019,65
2º / 2026	Salvador	233	148.873,07	2.515,50

Tabela de controle produzida pelas views do banco local. Os valores derivam exclusivamente dos arquivos fornecidos. Nesta base, todos os empreendedores têm renda informada; a regra do denominador permanece preparada para casos ausentes. Resultados são arredondados somente para exibição.

Limites de interpretação

Brasil, Bahia e Salvador são recortes sobrepostos. Não devem ser somados. Uma pessoa pode aparecer nos dois trimestres; os 48.680 registros de empreendedoras dos dois períodos não representam 48.680 mulheres distintas.

Formalização aqui significa possuir CNPJ no negócio, conforme V4019, e não uma medida abrangente de formalidade de todas as relações de trabalho. Fora de empregadores e conta própria, formalizada é NULL.

Rendas são habituais do trabalho principal e nominais. Comparações de poder de compra exigem deflacionamento. As estimativas são pontuais: erros padrão e intervalos de confiança exigirão o tratamento do desenho amostral e a avaliação dos pesos replicados, que permanecem nos originais.

Estudos complementares do Sebrae e a referência anual de 2021 não foram unidos aos TXT nem tratados como resultados trimestrais de 2026.

07 / Reprodução e conclusão da etapa em nuvem

Processo entregue

Arquivo / grupo	Uso
scripts/etl.py	Lê TXT por layout, valida, filtra, deduplica e exporta CSV/Parquet com auditoria.
scripts/verificar_artefatos.py	Compara todas as células entre formatos, confere hashes, indicadores e unicidade.
scripts/carregar_postgres.py	Carrega dimensões, fontes e observações em uma transação e gera evidência após commit.
sql/01, 02 e 03	DDL, views e consultas de validação.
dados/empreendedorismo_feminino.dump	Backup restaurável da estrutura e dos dados do PostgreSQL local.
README.md / requirements.txt	Comandos, dependências fixadas, regras e orientações de publicação.

Passos que faltam para comprovar nuvem

1. Criar o serviço PostgreSQL do projeto no Aiven e obter a conexão e o certificado CA.
2. Configurar PGCONNECTION por mecanismo seguro, com sslmode=verify-full e sslrootcert.
3. Executar o carregador sem --local em banco exclusivo do projeto.
4. Conferir as contagens, TLS, tamanho do banco e espaço livre; executar sql/03_validacao.sql.
5. Anexar carga_nuvem.json, resumo_nuvem.csv e evidência do serviço hospedado, sem senha.
6. Disponibilizar código, documentação e Parquet no repositório github.com/yLu4n/big_data; distribuir o ZIP e seus hashes.

O usuário informou que ainda não existe serviço Aiven. Por isso, a carga em nuvem e sua comprovação não foram realizadas. A conexão local usada na validação não utilizou SSL e não foi apresentada como conexão remota. A configuração local está em config/postgres.local.json, sem senha. O iniciador PowerShell solicita a senha e o carregador bloqueia recargas sem --substituir. O modo de nuvem exige TLS verificado.

Fontes e rastreabilidade

Solicitação: LUAN VICTOR CORTES DOS SANTOS CHAGAS BORGES - Solicitação de Entrega Técnica fase 2-1.pdf, páginas 1-2.
Especificação: Empeendedorismo_Feminino_Levantamento_Parametros_Tipagem.pdf, páginas 1-4.
Dados: PNADC_012026.txt e PNADC_022026.txt.
Metadados: input_PNADC_trimestral.txt, dicionario_PNADC_microdados_trimestral.xls e Variaveis_PNADC_Trimestral.xls.

A documentação fornecida indica o diretório público do IBGE para microdados trimestrais de 2026. Nesta execução, a ingestão ocorreu a partir da cópia local indicada pelo usuário. A referência a Sebrae é contextual e não constitui uma segunda base incorporada.

A evidência da execução local está em evidencias/carga_local.json, validacao_local.txt, resumo_local.csv e verificacao_artefatos.json. estrutura_postgres.json documenta cada tabela, seus campos, tipos, relações e contagens. Os hashes completos das entradas e saídas estão na auditoria; o manifesto do pacote identifica os demais arquivos entregues.