ENTREGA TÉCNICA / FASE 2

# Empreendedorismo Feminino no Brasil

## Unificação, tratamento, modelagem e armazenamento dos dados

Equipe: Kauã Kley, Luan Victor e Beatriz Costa
PNADC trimestral | 1º e 2º trimestres de 2026
Base fase2-v1 / entrega fase2-v2 | Preparada em 13/10/2026

| Resultado verificado | Quantidade |
|---|---|
| Linhas originais dos dois arquivos | 1.032.879 |
| Observações de ocupados na base tratada | 464.457 |
| Campos de origem / indicadores / rastreabilidade | 21 / 5 / 2 |
| Registros inválidos, duplicatas ou conflitos | 0 |

### Situação da atividade

| Entregável | Situação |
|---|---|
| 1. Base de dados tratada | Concluído: CSV e Parquet, tipos e auditoria. |
| 2. Processo de tratamento | Concluído: Python, SQL e documentação. Código e Parquet publicados: github.com/yLu4n/big_data (main). |
| 3. Banco de dados em nuvem | big_data em localhost:5432, esquema ef, carregado e validado. Hospedagem Aiven pendente: serviço ainda não criado. |

A entrega contém uma base efetivamente processada e o banco big_data carregado e validado no esquema ef. A etapa de nuvem permanece pendente, conforme informação do usuário; nenhuma evidência de hospedagem foi simulada.

Unidade de análise: observação de pessoa por trimestre. A soma de registros dos dois períodos não representa pessoas distintas no semestre.

# 02 / Origem e decisões de tratamento

## Fontes e versão utilizada

Os dois TXT, o layout SAS e os dicionários XLS foram lidos na pasta Projeto_Empreendedorismo_Feminino fornecida pelo usuário. A documentação atribui a fonte à PNAD Contínua trimestral do IBGE. Os arquivos originais permaneceram intactos. A autenticidade externa não foi revalidada por novo download.

| Arquivo | Originais | Ocupados | Fora do universo |
|---|---|---|---|
| PNADC_012026.txt | 511.149 | 228.357 | 282.792 |
| PNADC_022026.txt | 521.730 | 236.100 | 285.630 |
| Total | 1.032.879 | 464.457 | 568.422 |

Todas as linhas tinham 3.478 caracteres, sem a quebra de linha. As 21 variáveis foram conferidas entre posições do layout SAS, posições do dicionário e disponibilidade nos dois trimestres.

| Decisão | Aplicação e justificativa |
|---|---|
| Filtro de ocupação | VD4002=1. Preserva o universo definido no levantamento. |
| Geografia e sexo | Todas as UFs e ambos os sexos. Bahia e Salvador são indicadores para consultas. |
| Valores ausentes | Brancos opcionais viram NULL. Sem imputação de renda e sem substituição por zero. |
| Precisão | Peso e renda convertidos com Decimal; identificadores textuais preservam zeros. |
| Duplicatas e erros | Mesma chave e linha idêntica: remover repetição. Conteúdo divergente: excluir todas as ocorrências da chave e registrar para revisão. |
| Volume e memória | Leitura em fluxo; deduplicação SQLite em disco; exportação em blocos de 25.000. Sem subamostragem ou agregação antes da carga. |

## Proveniência verificável

**PNADC_012026.txt** | 1.778.798.520 bytes
SHA-256: 8406bfc994e69e1334b46396a17d0fd1f5d52948ec952107c8bc4d6f95f6703d

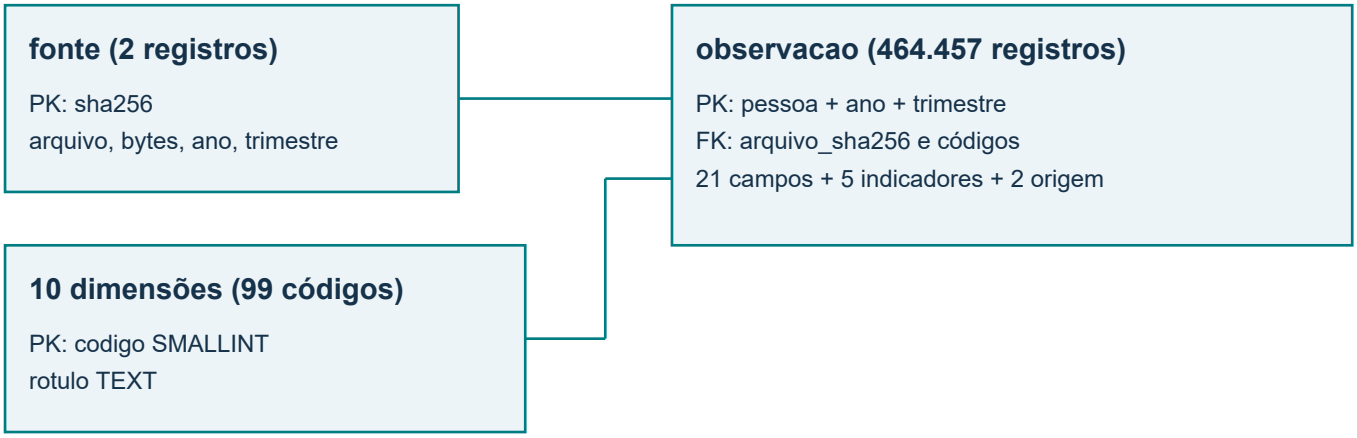
**PNADC_022026.txt** | 1.815.620.400 bytes
SHA-256: 03e399334ea304f4d0cc4444702c395ad9b369163c1e760ebc875b48c3a2c80e

Cada observação conserva o hash do arquivo e o número da linha original. Os hashes do layout e dos dicionários, além dos artefatos tratados, estão em dados/auditoria.json.

# 03 / Modelagem relacional

## Estrutura do esquema ef

O modelo mantém o detalhe pessoa-trimestre em uma tabela de observações e separa rótulos em dimensões. Essa escolha reduz repetição de texto, valida códigos com chaves estrangeiras e facilita filtros e agregações sem perder a rastreabilidade.




| Entidade | Campos e relacionamento |
|---|---|
| fonte | arquivo VARCHAR(80), sha256 CHAR(64) PK, bytes BIGINT, ano SMALLINT e trimestre SMALLINT. |
| observacao | Chave composta: ano, trimestre, upa, v1008, v1014, v1016 e v2003. UNIQUE adicional: arquivo_sha256 + linha_origem. |
| dim_uf e dim_capital | UF e capital municipal. Cada código na observação referencia a dimensão correspondente. |
| dim_v2007 e dim_v2010 | Sexo e cor/raça, incluindo códigos previstos como ignorado. |
| dim_vd3004 e dim_vd4002 | Nível de instrução e condição de ocupação. A tabela fato aceita somente ocupados. |
| dim_vd4009 e dim_vd4010 | Posição/categoria de emprego e grupamento de atividade. |
| dim_v4019 e dim_v4018 | Registro CNPJ e faixa de pessoas no negócio. Cada dimensão usa codigo SMALLINT e rotulo TEXT. |

## Integridade e índices

CHECKs validam período, ocupação, idade, peso, renda, identificação, geografia e indicadores. Há índice de período/UF/sexo e índice parcial para empreendedoras. O SQL completo está em sql/01_estrutura.sql. As chaves de pessoa incluem trimestre para preservar reaparições entre períodos.

# 04 / Campos e tipos da base tratada

Nomes físicos em minúsculas, correspondentes às variáveis de origem. NULL é permitido somente quando indicado. O dicionário JSON inclui posição e largura no TXT.

| Campo | Significado / regra | Tipo PostgreSQL | NULL |
|---|---|---|---|
| ano | Ano de referência | SMALLINT | Não |
| trimestre | Trimestre | SMALLINT | Não |
| uf | Unidade da Federação | SMALLINT | Não |
| capital | Município da capital | SMALLINT | Sim |
| upa | Unidade Primária de Amostragem | VARCHAR(9) | Não |
| estrato | Estrato amostral | VARCHAR(7) | Não |
| v1008 | Seleção do domicílio | VARCHAR(2) | Não |
| v1014 | Painel | VARCHAR(2) | Não |
| v1016 | Número da entrevista | VARCHAR(1) | Não |
| v1028 | Peso trimestral calibrado | NUMERIC(18,8) | Não |
| v2003 | Ordem da pessoa | VARCHAR(2) | Não |
| v2007 | Sexo | SMALLINT | Não |
| v2009 | Idade em anos | SMALLINT | Não |
| v2010 | Cor ou raça | SMALLINT | Não |
| vd3004 | Nível de instrução | SMALLINT | Não |
| vd4002 | Condição de ocupação | SMALLINT | Não |
| vd4009 | Posição e categoria do emprego | SMALLINT | Não |
| v4019 | Registro no CNPJ | SMALLINT | Sim |
| v4018 | Faixa de pessoas no negócio | SMALLINT | Sim |
| vd4010 | Grupamento de atividade | SMALLINT | Não |
| vd4016 | Renda habitual do trabalho principal | NUMERIC(12,2) | Sim |
| is_bahia | UF=29 | BOOLEAN | Não |
| is_salvador | UF=29 e Capital=29 | BOOLEAN | Não |
| is_empreendedor | VD4009 em 8 ou 9 | BOOLEAN | Não |
| is_empreendedora | Mulher e empreendedora | BOOLEAN | Não |
| formalizada | CNPJ; apenas empreendedores | BOOLEAN | Sim |
| arquivo_sha256 | SHA-256 da fonte original | CHAR(64) | Não |
| linha_origem | Linha original do TXT, iniciada em 1 | BIGINT | Não |

A renda é nominal, em reais. O peso mantém oito casas decimais sem conversão intermediária a ponto flutuante. V4018 é uma faixa e não um número exato de pessoas.

# 05 / Validação executada e armazenamento

## Carga real no PostgreSQL local

A conexão informada pelo usuário foi configurada em localhost:5432/big_data, no PostgreSQL 18.6. O esquema ef foi criado e carregado com chaves, restrições e views. As tabelas existentes no esquema empreendedorismo não foram alteradas. O banco informado permanece disponível; o backup de ef foi restaurado e conferido em outra instância temporária.

| Verificação | Resultado |
|---|---|
| Linhas carregadas / fontes / dimensões | 464.457 / 2 / 10 (99 códigos) |
| Contagens por trimestre | 1º: 228.357; 2º: 236.100 |
| Chaves repetidas no PostgreSQL | 0 grupos |
| Inconsistências de ocupação, peso, idade e indicadores | 0 |
| CSV versus Parquet | Todas as células conferidas: 464.457 linhas e 28 colunas |
| Hashes dos artefatos tratados | Conferidos; equivalem à auditoria |
| NULL em renda / renda zero informada | 9.261 / 0 |
| CNPJ ausente entre empreendedores | 0 |

## Ausências preservadas

| Campo | Nulos | Interpretação |
|---|---|---|
| capital | 349.127 | Não identificado como capital no campo. |
| v4019 / formalizada | 317.732 | Fora do universo de empreendedores nesta base. |
| v4018 | 92.868 | Ausência preservada conforme universo da pergunta. |
| vd4016 | 9.261 | Renda ausente; não transformada em zero. |

## Volume medido nesta execução

| Artefato | Tamanho |
|---|---|
| TXT originais (dois arquivos) | 3.594.418.920 bytes (3,59 GB) |
| CSV tratado | 82.825.879 bytes (82,83 MB) |
| Parquet tratado | 6.504.400 bytes (6,50 MB) |
| Tabela de observações e índices | 182.091.776 bytes (182,09 MB) |
| Banco big_data (todos os esquemas) | 305.469.119 bytes (305,47 MB) |

MB e GB usam base decimal. O esquema ef ocupa 182.509.568 bytes. O volume de big_data inclui outros esquemas e índices; não corresponde ao Parquet. A medida local de aproximadamente 323 MB citada no levantamento não foi reutilizada como resultado: este modelo foi medido novamente. O consumo no Aiven só poderá ser confirmado após a carga.

# 06 / Views e conferência das estimativas

## Estimativas pontuais por trimestre

As views v_recortes, v_resumo_geografico e v_perfil_empreendedores preservam o detalhe no banco e calculam resumos na consulta. O total estimado é a soma de V1028. A renda média usa soma(peso × renda) / soma(peso), considerando no denominador apenas observações com renda informada no mesmo grupo.

## Conferência das empreendedoras

| Trimestre | Recorte | Amostra | Estimativa ponderada | Renda média (R$) |
|---|---|---|---|---|
| 1º / 2026 | Brasil | 23.902 | 10.213.256,46 | 3.388,03 |
| 1º / 2026 | Bahia | 1.152 | 692.208,64 | 1.817,88 |
| 1º / 2026 | Salvador | 227 | 154.568,58 | 2.282,86 |
| 2º / 2026 | Brasil | 24.778 | 10.320.820,78 | 3.455,99 |
| 2º / 2026 | Bahia | 1.219 | 699.114,10 | 2.019,65 |
| 2º / 2026 | Salvador | 233 | 148.873,07 | 2.515,50 |

Tabela de controle produzida pelas views do banco local. Os valores derivam exclusivamente dos arquivos fornecidos. Nesta base, todos os empreendedores têm renda informada; a regra do denominador permanece preparada para casos ausentes. Resultados são arredondados somente para exibição.

## Limites de interpretação

Brasil, Bahia e Salvador são recortes sobrepostos. Não devem ser somados. Uma pessoa pode aparecer nos dois trimestres; os 48.680 registros de empreendedoras dos dois períodos não representam 48.680 mulheres distintas.

Formalização aqui significa possuir CNPJ no negócio, conforme V4019, e não uma medida abrangente de formalidade de todas as relações de trabalho. Fora de empregadores e conta própria, formalizada é NULL.

Rendas são habituais do trabalho principal e nominais. Comparações de poder de compra exigem deflacionamento. As estimativas são pontuais: erros padrão e intervalos de confiança exigirão o tratamento do desenho amostral e a avaliação dos pesos replicados, que permanecem nos originais.

Estudos complementares do Sebrae e a referência anual de 2021 não foram unidos aos TXT nem tratados como resultados trimestrais de 2026.