ENTREGA TÉCNICA / FASE 2

Empreendedorismo Feminino Bahia e Salvador

Unificação, tratamento, modelagem e armazenamento dos dados

Equipe: Kauã Kley, Luan Victor e Beatriz Costa
PNADC trimestral | 1º e 2º trimestres de 2026
Entrega fase2-bahia-aiven-v1 | Atualizada em 14/10/2026

Resultado verificado	Quantidade
Linhas originais dos dois arquivos	1.032.879
Observações de ocupados da Bahia	20.706
Salvador, incluído no total da Bahia	3.382
Campos de origem / indicadores / rastreabilidade	21 / 5 / 2
Registros inválidos, duplicatas ou conflitos	0

Recorte geográfico atual

A base contém exclusivamente UF=29, abrangendo toda a Bahia e incluindo Salvador. Capital=29 identifica Salvador dentro desse total. O recorte estadual foi solicitado pelo usuário e substitui a seleção nacional prevista inicialmente no levantamento. Ambos os sexos e todas as posições na ocupação permanecem.

Entregável	Situação
1. Base tratada	CSV e Parquet exclusivamente da Bahia, com auditoria e proveniência.
2. Processo	Python, SQL e documentação atualizados em github.com/yLu4n/big_data (main).
3. Banco de dados	Aiven: defaultdb, esquema ef, carregado e validado. 20.706 observações disponíveis com conexão TLS.

Unidade: observação de pessoa por trimestre. Salvador é subconjunto da Bahia; esses recortes não devem ser somados. Reaparições entre trimestres não são pessoas distintas no semestre.

02 / Origem e decisões de tratamento

Fontes e versão utilizada

A nova execução leu os dois TXT originais, o layout SAS e os dicionários XLS da pasta de projeto fornecida. A fonte é atribuída à PNAD Contínua trimestral do IBGE pela documentação. Os originais permaneceram intactos; seus hashes identificam a versão utilizada.

Arquivo	Originais	Ocupados Brasil	Outras UFs	Base Bahia
PNADC_012026.txt	511.149	228.357	218.295	10.062
PNADC_022026.txt	521.730	236.100	225.456	10.644
Total	1.032.879	464.457	443.751	20.706

Das linhas originais, 568.422 ficaram fora do universo de ocupados. Entre os ocupados, 443.751 pertenciam a outras UFs e foram excluídos pelo recorte. Não são registros inválidos. Todas as linhas tinham 3.478 caracteres, sem a quebra de linha.

Decisão	Aplicação e justificativa
Ocupação e geografia	VD4002=1 e UF=29. O projeto passa a analisar apenas a Bahia; Capital=29 identifica Salvador.
Sexo e ocupação	Ambos os sexos e todas as posições. Permite comparações entre empreendedoras e os demais ocupados da Bahia.
Valores ausentes	Brancos opcionais viram NULL. Sem imputação de renda ou substituição por zero.
Precisão	Peso e renda usam Decimal; identificadores textuais conservam zeros.
Duplicatas e erros	Linha idêntica sob a mesma chave: remover repetição. Conteúdo divergente: retirar todas as ocorrências da chave para revisão.
Memória e volume	Leitura em fluxo, deduplicação em disco e exportação em blocos. Não há subamostragem nem agregação antes da carga.

Proveniência verificável

PNADC_012026.txt | 1.778.798.520 bytes
SHA-256: 8406bfc994e69e1334b46396a17d0fd1f5d52948ec952107c8bc4d6f95f6703d

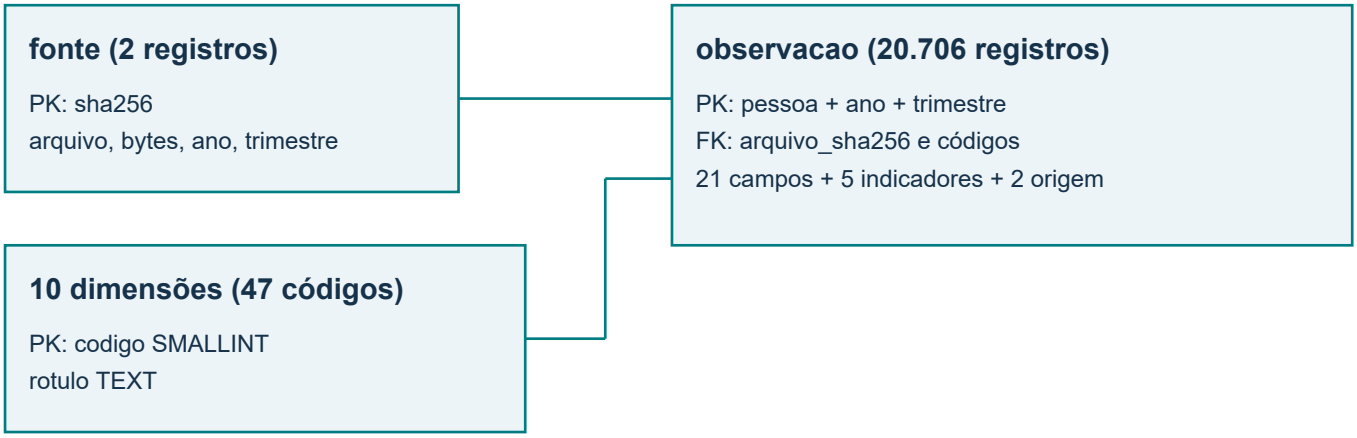
PNADC_022026.txt | 1.815.620.400 bytes
SHA-256: 03e399334ea304f4d0cc4444702c395ad9b369163c1e760ebc875b48c3a2c80e

Cada registro conserva o hash da fonte e a linha original. Todas as células da nova base foram comparadas ao recorte UF=29 da versão nacional anterior e coincidiram.

03 / Modelagem relacional

Estrutura do esquema ef

O modelo mantém o detalhe pessoa-trimestre em uma tabela de observações e separa rótulos em dimensões. Essa escolha reduz repetição de texto, valida códigos com chaves estrangeiras e facilita filtros e agregações sem perder a rastreabilidade.



Entidade	Campos e relacionamento
fonte	arquivo VARCHAR(80), sha256 CHAR(64) PK, bytes BIGINT, ano SMALLINT e trimestre SMALLINT.
observacao	Chave composta: ano, trimestre, upa, v1008, v1014, v1016 e v2003. UNIQUE adicional: arquivo_sha256 + linha_origem.
dim_uf e dim_capital	UF e capital municipal. Cada código na observação referencia a dimensão correspondente.
dim_v2007 e dim_v2010	Sexo e cor/raça, incluindo códigos previstos como ignorado.
dim_vd3004 e dim_vd4002	Nível de instrução e condição de ocupação. A tabela fato aceita somente ocupados.
dim_vd4009 e dim_vd4010	Posição/categoria de emprego e grupamento de atividade.
dim_v4019 e dim_v4018	Registro CNPJ e faixa de pessoas no negócio. Cada dimensão usa codigo SMALLINT e rotulo TEXT.

Integridade e índices

CHECKs validam período, ocupação, idade, peso, renda, identificação, geografia e indicadores. Há índice de período/UF/sexo e índice parcial para empreendedoras. O SQL completo está em sql/01_estrutura.sql. As chaves de pessoa incluem trimestre para preservar reaparições entre períodos.

A dimensão UF e a dimensão Capital contêm somente o código 29. A restrição ck_recorte_bahia impõe UF=29. Em recargas de uma versão nacional anterior, sql/04_recorte_bahia.sql aplica a restrição após esvaziar as tabelas, dentro da mesma transação.

04 / Campos e tipos da base tratada

Nomes físicos em minúsculas, correspondentes às variáveis de origem. NULL é permitido somente quando indicado. O dicionário JSON inclui posição e largura no TXT.

Campo	Significado / regra	Tipo PostgreSQL	NULL
ano	Ano de referência	SMALLINT	Não
trimestre	Trimestre	SMALLINT	Não
uf	Unidade da Federação	SMALLINT	Não
capital	Município da capital	SMALLINT	Sim
upa	Unidade Primária de Amostragem	VARCHAR(9)	Não
estrato	Estrato amostral	VARCHAR(7)	Não
v1008	Seleção do domicílio	VARCHAR(2)	Não
v1014	Painel	VARCHAR(2)	Não
v1016	Número da entrevista	VARCHAR(1)	Não
v1028	Peso trimestral calibrado	NUMERIC(18,8)	Não
v2003	Ordem da pessoa	VARCHAR(2)	Não
v2007	Sexo	SMALLINT	Não
v2009	Idade em anos	SMALLINT	Não
v2010	Cor ou raça	SMALLINT	Não
vd3004	Nível de instrução	SMALLINT	Não
vd4002	Condição de ocupação	SMALLINT	Não
vd4009	Posição e categoria do emprego	SMALLINT	Não
v4019	Registro no CNPJ	SMALLINT	Sim
v4018	Faixa de pessoas no negócio	SMALLINT	Sim
vd4010	Grupamento de atividade	SMALLINT	Não
vd4016	Renda habitual do trabalho principal	NUMERIC(12,2)	Sim
is_bahia	UF=29	BOOLEAN	Não
is_salvador	UF=29 e Capital=29	BOOLEAN	Não
is_empreendedor	VD4009 em 8 ou 9	BOOLEAN	Não
is_empreendedora	Mulher e empreendedora	BOOLEAN	Não
formalizada	CNPJ; apenas empreendedores	BOOLEAN	Sim
arquivo_sha256	SHA-256 da fonte original	CHAR(64)	Não
linha_origem	Linha original do TXT, iniciada em 1	BIGINT	Não

A renda é nominal, em reais. O peso mantém oito casas decimais sem conversão intermediária a ponto flutuante. V4018 é uma faixa e não um número exato de pessoas.

05 / Validação executada e armazenamento

Carga real no PostgreSQL em nuvem

A base foi carregada no PostgreSQL 18.6 do Aiven, banco defaultdb, esquema ef. A conexão confirmou TLS 1.3 com sslmode=require, conforme os parâmetros fornecidos. A restrição CHECK (uf=29) impede outras UFs. Todas as células da base em nuvem coincidiram com o Parquet tratado. Não foi fornecido CA para validação do certificado.

Verificação	Resultado
Observações / fontes / dimensões	20.706 / 2 / 10 (47 códigos)
Contagens por trimestre	1º: 10.062; 2º: 10.644
Salvador por trimestre	1º: 1.645; 2º: 1.737
Registros com UF diferente de 29	0
Chaves repetidas e inconsistências	0
CSV versus Parquet	Todas as células iguais; 20.706 linhas e 28 colunas
Comparação com a versão anterior	Igualdade integral com o recorte UF=29
Conferência integral Aiven / Parquet	20.706 observações; todas as células iguais

Ausências preservadas

Campo	Nulos	Interpretação
capital	17.324	Bahia fora do recorte de Salvador.
v4019 / formalizada	13.660	Fora do universo de empreendedores nesta base.
v4018	4.330	Ausência preservada conforme a pergunta.
vd4016	491	Renda ausente; não transformada em zero.

Volume medido nesta execução

Artefato	Tamanho em bytes
CSV da Bahia	3.672.597
Parquet da Bahia	297.712
Tabela de observações e índices	8.609.792
Esquema ef: tabelas e índices	8.978.432
defaultdb no Aiven	17.299.135

As medidas de tabela, esquema e banco foram verificadas no Aiven. O host é pg-3746e955-bigdatalkb.f.aivencloud.com, porta 22835. A conexão sem senha está documentada em config/postgres.aiven.json; as evidências da carga, estrutura e TLS acompanham a entrega.

06 / Views e conferência das estimativas

Estimativas pontuais por trimestre

As views v_recortes, v_resumo_geografico e v_perfil_empreendedores oferecem somente Bahia e Salvador. Não há resumo Brasil com dados restritos ao estado. A soma de V1028 estima o total; a renda média usa soma(peso × renda) / soma(peso), apenas entre observações com renda informada no mesmo grupo.

Conferência das empreendedoras

Trimestre	Recorte	Amostra	Estimativa ponderada	Renda média (R$)
1º / 2026	Bahia	1.152	692.208,64	1.817,88
1º / 2026	Salvador	227	154.568,58	2.282,86
2º / 2026	Bahia	1.219	699.114,10	2.019,65
2º / 2026	Salvador	233	148.873,07	2.515,50

Tabela de controle produzida pelas views do banco. Resultados vêm dos arquivos fornecidos e são arredondados somente para exibição. Empreendedoras na amostra da Bahia: 2.371 observações nos dois trimestres, das quais 460 são de Salvador.

Limites de interpretação

Salvador está incluído na Bahia. Não somar os dois recortes. As 20.706 observações do semestre não representam 20.706 pessoas distintas, pois uma pessoa pode reaparecer na pesquisa.

Formalização significa registro do negócio no CNPJ, apenas para empregadores e conta própria. Fora desse universo, formalizada é NULL. A amostra estadual mantém também empregados e trabalhadores familiares para comparações.

Rendas são habituais do trabalho principal e nominais. Comparações de poder de compra exigem deflacionamento. Erros padrão e intervalos de confiança exigem tratamento do desenho amostral e avaliação dos pesos replicados preservados nos originais. UPA, estrato e peso calibrado permanecem na base.

A filtragem estadual conserva os pesos originais, sem renormalização nem subamostragem adicional. Estudos complementares e a referência anual de 2021 não foram incorporados como resultados trimestrais de 2026.